

Comparaison de pourcentages

Pr S. El Fakir

Exemple

Dans une enquête épidémiologique, on interroge des malades atteints d'ulcère du duodénum et des sujets indemnes de cette pathologie quant à leurs antécédents de stress dans les mois précédents.

Au total, 1010 sujets ont été inclus dans l'étude, dont 367 malades. Parmi les malades, 347 avaient des antécédents de stress contre 555 parmi les sujets indemnes d'ulcère du duodénum.

Y a-t-il une association entre le stress et la survenue de l'ulcère du duodénum ?

Exemple

Dans une population, trois personnes sur dix sont atteintes d'une maladie M ; on souhaite mener une étude épidémiologique sur cette maladie, on tire à cet effet au hasard 50 personnes dans la population : on constate que 12 personnes sont atteintes de M.

La proportion de personnes atteintes de M dans l'échantillon diffère-t-elle significativement de celle de la population ?

Comparaison d'un pourcentage à une valeur théorique

Test du χ^2

Hypothèse nulle $H_0 : P = P_{H_0}$

Hypothèse alternative $H_1 : P \neq P_{H_0}$

Comparaison d'un pourcentage à une valeur théorique

	M^+	M^-	
Effectifs observés	O_1	O_2	n
Effectifs calculés	$C_1 = nP_{H_0}$	$C_2 = nQ_{H_0}$	n

Comparaison d'un pourcentage à une valeur théorique

Si H_0 est vraie et si n est assez grand :

$$\chi_o^2 = \frac{(O_1 - C_1)^2}{C_1} + \frac{(O_2 - C_2)^2}{C_2} \text{ suit une loi de } \chi^2 \text{ à 1 ddl}$$

=> règle de décision :

si $\chi_o^2 \geq 3,84$: rejet de H_0

si $\chi_o^2 < 3,84$: non rejet de H_0

Conditions d'application : C_1 et $C_2 \geq 5$

Exemple

Parmi 400 habitants représentatifs d'une région,
92 (23%) consomment des anti-dépresseurs

Ce pourcentage diffère-t-il de la valeur 20%
donnée par les chiffres de vente nationaux ?

$$H_0 : P = 0,20 \quad H_1 : P \neq 0,20$$

Exemple

Consommation d'anti-dépresseurs			
	Oui	Non	
Eff. observés	92	308	400
Eff. calculés	$400 \times 0,20 = 80$	$400 \times 0,80 = 320$	400

Exemple

Effectifs calculés $\geq 5 \Rightarrow$ conditions
d'application satisfaites

$$\chi_o^2 = \frac{(92 - 80)^2}{80} + \frac{(308 - 320)^2}{320} = 2,25$$

$\chi_o^2 < 3,84 \Rightarrow$ on ne rejette pas l'hypothèse H_o

Exemple

Conclusion :

On ne met pas en évidence de différence entre le pourcentage de consommateurs d'anti-dépresseurs dans la région et dans l'ensemble du pays.

Comparaison de deux pourcentages

$$H_0 : P_1 = P_2 \quad H_1 : P_1 \neq P_2$$

P_1 et P_2 : pourcentages vrais de malades
dans les populations 1 et 2

Observations :

- échantillon issu de la population 1 : n_1 et p_1
- échantillon issu de la population 2 : n_2 et p_2

Comparaison de deux pourcentages

	M ⁺	M ⁻		
E ₁	O ₁₁	O ₁₂	n ₁	$p_1 = \frac{O_{11}}{n_1}$
E ₂	O ₂₁	O ₂₂	n ₂	$p_2 = \frac{O_{21}}{n_2}$
	m ₁	m ₂	n	

C_{ij} = valeur attendue si H_0 est vraie = ?

Comparaison de deux pourcentages

Calcul des C_{ij}

	M ⁺	M ⁻		pourcentages observés
E ₁	$\begin{array}{c} O_{11} \\ (C_{11}) \end{array}$	$\begin{array}{c} O_{12} \\ (C_{12}) \end{array}$	n ₁	$p_1 = \frac{O_{11}}{n_1}$
E ₂	$\begin{array}{c} O_{21} \\ (C_{21}) \end{array}$	$\begin{array}{c} O_{22} \\ (C_{22}) \end{array}$	n ₂	$p_2 = \frac{O_{21}}{n_2}$
	m ₁	m ₂	n	

Si H_0 est vraie : $P_1 = P_2 = P$ (pourcentages vrais)

Comparaison de deux pourcentages

La meilleure estimation de P est obtenue en regroupant E_1 et E_2 .

$$\Rightarrow \hat{P} = \frac{m_1}{n}$$


Le nombre de sujets attendus dans la case (E_1M^+) est donc :

$$C_{11} = n_1 \hat{P} = n_1 \frac{m_1}{n} = \frac{n_1 m_1}{n}$$

Comparaison de deux pourcentages

De façon générale :

$$C_{ij} = \frac{n_i m_j}{n}$$



Comparaison de deux pourcentages

Test de Chi deux

$$H_0 : P_1 = P_2 \quad H_1 : P_1 \neq P_2$$

	M ⁺	M ⁻	
E ₁	O ₁₁ (c ₁₁)	O ₁₂ (c ₁₂)	n ₁
E ₂	O ₂₁ (c ₂₁)	O ₂₂ (c ₂₂)	n ₂
	m ₁	m ₂	n

$$p_1 = \frac{O_{11}}{n_1}$$

$$p_2 = \frac{O_{21}}{n_2}$$

Comparaison de deux pourcentages

Test de Chi deux

Si H_0 est vraie, et si la taille de l'échantillon est assez grande :

$$\chi_o^2 = \frac{(O_{11}-C_{11})^2}{C_{11}} + \frac{(O_{12}-C_{12})^2}{C_{12}} + \frac{(O_{21}-C_{21})^2}{C_{21}} + \frac{(O_{22}-C_{22})^2}{C_{22}}$$
$$= \sum \frac{(O-C)^2}{C} \text{ suit une loi de } \chi^2 \text{ avec 1 ddl}$$

avec $C_{ij} = \frac{n_i m_j}{n}$

Conditions d'application : $C_{ij} \geq 5$

Exemple

Consommation de tabac
pendant la grossesse

oui

non

Hypotrophie

45

(34,0)

68

(79,0)

113

Poids normal

748

(759,0)

1 778

(1 767,0)

2 526

793

1 846

2 639

Exemple

$$H_0 : P_1 = P_2 \quad H_1 : P_1 \neq P_2$$

P_1 = pourcentage vrai d'hypotrophie
dans la population des fumeuses

P_2 = pourcentage vrai d'hypotrophie
dans la population des non fumeuses

Conditions d'applications satisfaites : $C_{ij} \geq 5$

$$\begin{aligned}\chi_o^2 &= \frac{(45-34,0)^2}{34,0} + \frac{(68-79,0)^2}{79,0} + \frac{(748-759,0)^2}{759,0} + \frac{(1778-1767,0)^2}{1767,0} \\ &= \frac{(11)^2}{34,0} + \frac{(-11)^2}{79,0} + \frac{(-11)^2}{759,0} + \frac{(11)^2}{1767,0} = 5,37\end{aligned}$$

Exemple

$$\chi_o^2 = 5,37 \geq 3,84 \rightarrow \text{significatif}$$

$\Rightarrow$ Rejet de H_o :

P_1 et P_2 sont différents (au risque $\alpha = 5\%$)

Degré de signification : $p = P(\chi_1^2 > 5,37)$

$$(0,01 <) p < 0,025$$

Exemple

1. Jugement de signification

- Il y a une relation entre la consommation de tabac pendant la grossesse et l'hypotrophie du nouveau-né.
- On observe que la relation est dans le sens : plus d'hypotrophiques parmi les fumeuses.

Exemple

2. Jugement de causalité

On ne démontre pas de lien causal entre tabac et hypotrophie.

Autre expression du χ^2 à 1 ddl

	M ⁺	M ⁻	
E ₁	a	b	n ₁
E ₂	c	d	n ₂
	m ₁	m ₂	n

$$\chi_o^2 = \sum \frac{(O-C)^2}{C}$$

En réduisant au même dénominateur les 4 termes de la somme, on obtient :

$$\chi_o^2 = \frac{(ad-bc)^2 n}{n_1 n_2 m_1 m_2}$$

- Expression plus simple à calculer
- mais, ne pas oublier de vérifier que tous les C_i sont ≥ 5

Petits échantillons

Un (au moins) des C_{ij} est inférieur à 5 et tous les C_{ij} sont supérieurs ou égaux à 3

Correction de Yates :

$$\chi_c^2 = \sum \frac{(|O-C|-0,5)^2}{C}$$

qui suit une loi de χ^2 à 1 ddl (si H_0 est vraie)

Conditions d'application : $C_{ij} \geq 3$

Petits échantillons

Un (au moins) des C_{ij} est inférieur à 5 et tous les C_{ij} sont supérieurs ou égaux à 3

$$\chi_c^2 = \frac{\left(|ad-bc| - \frac{n}{2}\right)^2 n}{n_1 n_2 m_1 m_2}$$

Comparaison de plusieurs répartitions observées

- k classes de sujets : $A_1, \dots, A_k$
- p populations : $B_1, \dots, B_p$
- P_{ij} = pourcentage vrai de sujets dans la classe j de la population i

	A_1	A_2	...	A_j	...	A_k
B_1	P_{11}	P_{12}	...		...	P_{1k}
B_2	P_{21}	P_{22}	...		...	P_{2k}
...	...	...	...		...	...
B_i				P_{ij}		
...	...	...	...		...	...
B_p	P_{p1}	P_{p2}	...		...	P_{pk}

Comparaison de plusieurs répartitions observées

Hypothèses testées

$$\begin{aligned} H_0 : & P_{11} = P_{21} = \dots = P_{p1} \\ & P_{12} = P_{22} = \dots = P_{p2} \\ & \dots\dots\dots \\ & P_{1k} = P_{2k} = \dots = P_{pk} \end{aligned}$$

H_1 : une, au moins, des égalités n'est pas vraie.

Comparaison de plusieurs répartitions observées

Valeurs attendues si H_0 est vraie

	A_1	A_2	...	A_j	...	A_k	
B_1	O_{11} (C_{11})	O_{12} (C_{12})	...		...	O_{1k} (C_{1k})	n_1
B_2	O_{21} (C_{21})	O_{22} (C_{22})	...		...	O_{2k} (C_{2k})	n_2
...	...	...	...		...	...	...
B_i				O_{ij} (C_{ij})			
...	...	...	...		...	...	...
B_p	O_{p1} (C_{p1})	O_{p2} (C_{p2})	...		...	O_{pk} (C_{pk})	n_p
	m_1	m_2	...		...	m_k	n

Comparaison de plusieurs répartitions observées

$$C_{ij} = \frac{n_i m_j}{n}$$

♦ Test

On montre que, si H_0 est vraie (et si n est assez grand) :

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - C_{ij})^2}{C_{ij}} = \sum \frac{(O - C)^2}{C}$$

suit une loi de khi-2 avec $(p-1)(k-1)$ ddl

Comparaison de plusieurs répartitions observées

- On calcule la quantité observée sur l'échantillon :

$$\chi_o^2 = \sum \frac{(O-C)^2}{C}$$

- Rejet de H_0 , au risque α , si $\chi_o^2 \geq \chi_{(p-1)(k-1); \alpha}^2$
- Degré de signification : $p = P(\chi_{(p-1)(k-1)}^2 \geq \chi_o^2)$

ddl	α										
	0,975	0,95	0,90	0,50	0,30	0,20	0,10	0,05	0,025	0,01	0,001
1	0,00	0,00	0,02	0,45	1,07	1,64	2,71	3,84	5,02	6,63	10,83
2	0,05	0,10	0,21	1,39	2,41	3,22	4,61	5,99	7,38	9,21	13,82
3	0,22	0,35	0,58	2,37	3,66	4,64	6,25	7,81	9,35	11,34	16,27
4	0,48	0,71	1,06	3,36	4,88	5,99	7,78	9,49	11,14	13,28	18,47
5	0,83	1,15	1,61	4,35	6,06	7,29	9,24	11,07	12,83	15,09	20,52
6	1,24	1,64	2,20	5,35	7,23	8,56	10,64	12,59	14,45	16,81	22,46
7	1,69	2,17	2,83	6,35	8,38	9,80	12,02	14,07	16,01	18,48	24,32
8	2,18	2,73	3,49	7,34	9,52	11,03	13,36	15,51	17,53	20,09	26,12
9	2,70	3,33	4,17	8,34	10,66	12,24	14,68	16,92	19,02	21,67	27,88
10	3,25	3,94	4,87	9,34	11,78	13,44	15,99	18,31	20,48	23,21	29,59
11	3,82	4,57	5,58	10,34	12,90	14,63	17,28	19,68	21,92	24,72	31,26
12	4,40	5,23	6,30	11,34	14,01	15,81	18,55	21,03	23,34	26,22	32,91
13	5,01	5,89	7,04	12,34	15,12	16,98	19,81	22,36	24,74	27,69	34,53
14	5,63	6,57	7,79	13,34	16,22	18,15	21,06	23,68	26,12	29,14	36,12
15	6,26	7,26	8,55	14,34	17,32	19,31	22,31	25,00	27,49	30,58	37,70
16	6,91	7,96	9,31	15,34	18,42	20,47	23,54	26,30	28,85	32,00	39,25
17	7,56	8,67	10,09	16,34	19,51	21,61	24,77	27,59	30,19	33,41	40,79
18	8,23	9,39	10,86	17,34	20,60	22,76	25,99	28,87	31,53	34,81	42,31
19	8,91	10,12	11,65	18,34	21,69	23,90	27,20	30,14	32,85	36,19	43,82
20	9,59	10,85	12,44	19,34	22,77	25,04	28,41	31,41	34,17	37,57	45,31
21	10,28	11,59	13,24	20,34	23,86	26,17	29,62	32,67	35,48	38,93	46,80
22	10,98	12,34	14,04	21,34	24,94	27,30	30,81	33,92	36,78	40,29	48,27
23	11,69	13,09	14,85	22,34	26,02	28,43	32,01	35,17	38,08	41,64	49,73
24	12,40	13,85	15,66	23,34	27,10	29,55	33,20	36,42	39,36	42,98	51,18
25	13,12	14,61	16,47	24,34	28,17	30,68	34,38	37,65	40,65	44,31	52,62
26	13,84	15,38	17,29	25,34	29,25	31,79	35,56	38,89	41,92	45,64	54,05
27	14,57	16,15	18,11	26,34	30,32	32,91	36,74	40,11	43,19	46,96	55,48
28	15,31	16,93	18,94	27,34	31,39	34,03	37,92	41,34	44,46	48,28	56,89
29	16,05	17,71	19,77	28,34	32,46	35,14	39,09	42,56	45,72	49,59	58,30
30	16,79	18,49	20,60	29,34	33,53	36,25	40,26	43,77	46,98	50,89	59,70
40	24,43	26,51	29,05	39,34	44,16	47,27	51,81	55,76	59,34	63,69	73,40
60	40,48	43,19	46,46	59,33	65,23	68,97	74,40	79,08	83,30	88,38	99,61
100	74,22	77,93	82,36	99,33	106,91	111,67	118,50	124,34	129,56	135,81	149,45